

Regression Dataset for Household Income Analysis

Raquel Urbina - Rosángela Rodríguez - Natalia Sosa

Proyecto - Seminario Profesional I

Introducción / Objetivo

Comprender los factores que influyen en el ingreso de los hogares es importante para el análisis socioeconómico. En este proyecto se analiza un dataset con variables demográficas, educativas, laborales y de vivienda para estudiar su relación con el ingreso anual del hogar.

Para ello se busca predecir el ingreso anual del hogar mediante modelos de regresión supervisada, comparando cinco algoritmos para identificar el modelo con mejor desempeño y mayor capacidad para estimar el ingreso de forma precisa.

Descripción del dataset

- 10,000 **registros** y 14 **variables** originales
- Variable objetivo:** Income (USD)
- Sin **valores faltantes** ni **registros duplicados**
- Variables **numéricas** y **categorías**
- Distribución del ingreso **altamente sesgada**

Variables Principales

Edad, nivel educativo, ocupación, experiencia laboral, dependientes, ubicación, estado laboral, estado civil, tamaño del hogar, tipo y tenencia de vivienda, género y transporte.

Metodología

- Carga y revisión inicial del dataset
- Análisis exploratorio de datos
- Limpieza y validación del dataset
- Ingeniería de características
- Codificación One-Hot Encoding para variables categóricas
- Transformación logarítmica de **Income**
- División **80%** entrenamiento y **20%** prueba
- Entrenamiento y comparación de modelos
- Evaluación con métricas de regresión


Modelos Evaluados

- Ridge Regression
- Random Forest
- Extra Trees**
- XGBoost
- LightGBM


Resultados

	R2_log	RMSLE	MAE	Median_AE	RMSE	R2_real	Train_seconds
Model							
Extra Trees	0.2454	1.3181	\$722,780.59	\$93,455.11	\$1,800,558.11	-0.0468	6.6052
Random Forest	0.1977	1.3592	\$736,803.87	\$112,760.11	\$1,831,340.76	-0.0829	7.5567
LightGBM	0.1229	1.4211	\$751,633.06	\$116,562.93	\$1,847,979.93	-0.1026	0.4042
XGBoost	0.0927	1.4454	\$757,108.44	\$118,896.70	\$1,853,044.57	-0.1087	0.4502
Ridge	0.0386	1.4878	\$764,242.17	\$106,379.34	\$1,861,424.57	-0.1187	0.1142

Presentó el mejor equilibrio entre error bajo y capacidad de capturar relaciones no lineales en los datos



Es un ensamble de árboles de decisión. Cada árbol genera una predicción distinta y el resultado final se obtiene promediando las predicciones del conjunto. Este enfoque permite capturar relaciones no lineales entre las variables del hogar y el ingreso.



Árbol truncado para mostrar cómo se ve una unidad interna del modelo.

Conclusiones

- Extra Trees** fue el modelo con mejor capacidad predictiva.
- La transformación logarítmica fue fundamental para manejar la alta asimetría del ingreso.
- Los modelos basados en árboles superaron al modelo lineal Ridge
- Las variables laborales, educativas y de vivienda aportaron información relevante
- Los valores extremos siguen siendo un reto para predecir ingresos con alta precisión

Mejoras a futuro

- Aplicar validación cruzada para obtener resultados más robustos
- Optimizar hiperparámetros de los modelos
- Mejorar el tratamiento de valores atípicos
- Evaluar modelos adicionales como CatBoost o regresión por cuantiles
- Incorporar técnicas de interpretabilidad como SHAP
- Validar el modelo con datos reales o externos

Código QR



Referencias

- [Dataset](#)
- [Colab](#)
- [Ridge Regression](#)
- [Random Forest](#)
- [Extra Trees](#)
- [XGBoost](#)
- [LightGBM](#)