

Regression Dataset for Household Income Analysis

Raquel Urbina, Rosángela Rodríguez, Natalia Sosa

Proyecto

Seminario Profesional I

Introducción

Comprender los factores que influyen en el ingreso de los hogares es un aspecto importante en el análisis socioeconómico. En este proyecto se busca predecir el ingreso anual del hogar utilizando variables demográficas, educativas y laborales del miembro principal del hogar.

Para ello se utiliza un enfoque de aprendizaje supervisado basado en modelos de regresión, aplicados a un dataset con características socioeconómicas del hogar. El objetivo es identificar patrones en los datos y construir un modelo capaz de estimar el ingreso anual de forma precisa.

Descripción del dataset

- 10,000 registros y 14 variables
- Variable objetivo: Income (USD)
- Sin valores faltantes ni duplicados
- Distribución altamente sesgada con valores extremos de ingreso.

Variables Principales

Edad, educación, ocupación, experiencia laboral, dependientes, ubicación, estado laboral, estado civil, tamaño del hogar, vivienda y transporte.


Metodología

- Análisis exploratorio de datos
- Limpieza y validación del dataset
- Ingeniería de características
- One-Hot Encoding para variables categóricas
- Transformación logarítmica de Income
- División 80% entrenamiento y 20% prueba
- Entrenamiento y comparación de modelos

Modelos Evaluados


- Ridge Regression
- Random Forest
- Extra Trees
- XGBoost
- LightGBM

Resultados



Model	R2_log	RMSLE	MAE	Median_AE	RMSE	R2_real	Train_seconds
Extra Trees	0.2454	1.3181	\$722,780.59	\$93,455.11	\$1,800,558.11	-0.0468	6.6052
Random Forest	0.1977	1.3592	\$736,803.87	\$112,760.11	\$1,831,340.76	-0.0829	7.5567
LightGBM	0.1229	1.4211	\$751,633.06	\$116,562.93	\$1,847,979.93	-0.1026	0.4042
XGBoost	0.0927	1.4454	\$757,108.44	\$118,896.70	\$1,853,044.57	-0.1087	0.4502
Ridge	0.0386	1.4878	\$764,242.17	\$106,379.34	\$1,861,424.57	-0.1187	0.1142

Arquitectura del modelo ganador: Extra Trees



Conclusiones

- Extra Trees fue el modelo con mejor capacidad predictiva.
- La transformación logarítmica fue fundamental para manejar la alta asimetría del ingreso.
- Los modelos basados en árboles superaron a los modelos lineales.
- Los valores extremos continúan representando un desafío para la predicción del ingreso.

Mejoras a futuro

- Mejorar la calidad y consistencia del dataset.
- Evaluar modelos adicionales y técnicas más avanzadas.
- Aplicar un tratamiento más robusto de valores atípicos.
- Mejor tratamiento de outliers
- Incorporación de técnicas de interpretabilidad (SHAP)

Código QR



Referencias

- Dataset
- Colab
- Ridge Regression
- Random Forest
- Extra Trees
- XGBoost
- LightGBM